



Intrusion Detection for OAuth

Florian Nehmer

Einleitung (1)

■ Open Authorization Framework 2.0 (OAuth)

- Login-Prozess: "Weiter mit [Apple, Google, ...]"
 - Single Sign On
 - Smart Devices
- RFC6749 (2012)
 - 30 RFCs die mit OAuth in Verbindung stehen
- OAuth 2.1 in Arbeit

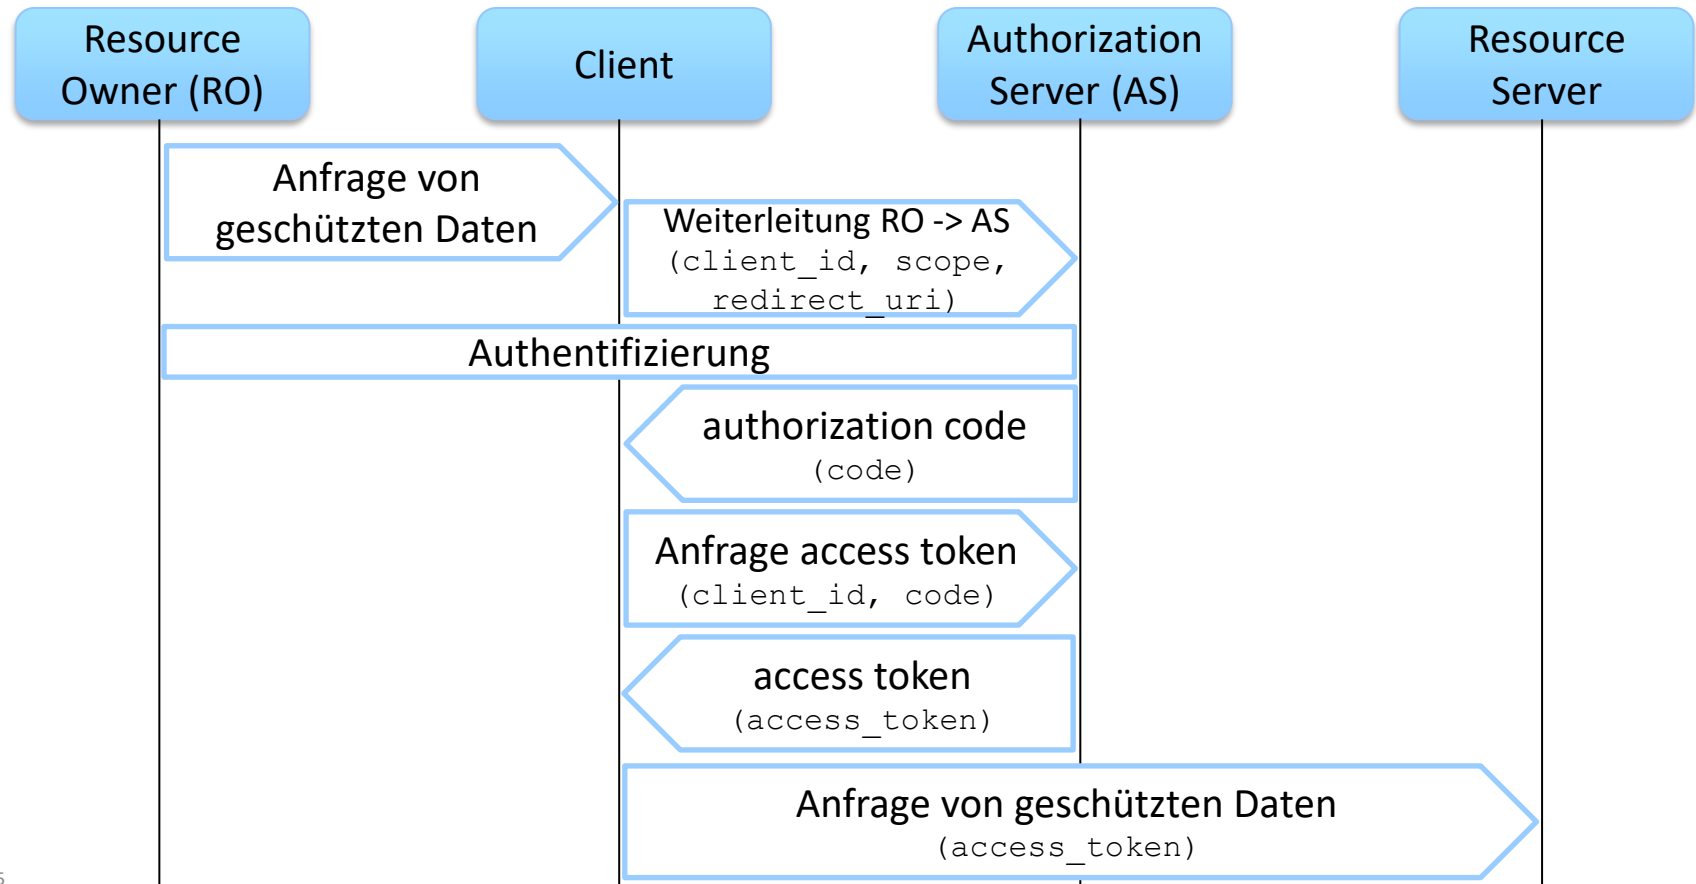
■ Forschungsfragen

- Welche Arten von Sicherheitsbedrohungen existieren aktuell für Implementierungen des OAuth Protokolls?
- Wie kann man Anomalieerkennung einsetzen, um Angriffe auf das OAuth Protokoll zu erkennen?

Einleitung (2)

- Methoden und Verfahren
 - Kategorisierung verschiedener OAuth Bedrohungen
 - Implementierung einer OAuth Testumgebung
 - Netzwerkdatergenerierung
 - Anomalie-Erkennung
 - Word2Vec Enkodierung von Netzwerkdaten
 - Clustering Algorithmen zur Anomalieerkennung

OAuth 2.0 Protokoll Funktionsweise



OAuth 2.0 Bedrohungen

1. Leak von Credentials & Session Übernahme

2. Manipulation von Weiterleitungen

3. Umgehung von Integritätsmaßnahmen

4. Credential Injection

1. Leak von Credentials & Session Übernahme

- **Ausnutzung von Web Mechanismen und Umgebungen zur Übernahme von Session Daten**
 - Autorisierungsdaten / Credentials sichtbar in Logdateien und Services
 - Clickjacking
 - 307 Redirect

2. Manipulation von Weiterleitungen

- Manipulation des Opfers zur Weiterleitung der Autorisierungsdaten zum Angreifer
 - Unzureichende Überprüfung des *redirect_uri* Parameters
 - AS leitet zu Phishing Seite weiter
 - Mix-Up Angriff

3. Umgehung von Integritätsmaßnahmen

- Maßnahmen, die die Integrität des Resource Owners bewahren sollen werden umgangen
 - PKCE Downgrade Angriff
 - Cross Site Request Forgery

4. Credential Injection

- Geklaute Credentials werden benutzt, um an geschützte Daten zu gelangen
 - Authorization Code Injection
 - Access Token Injection

Fazit Bedrohungslage

- Verschiedenste Angriffsvektoren sind denkbar
- Viele involvierte Komponenten
 - Mensch
 - Browser
 - Client Applikation
 - Authorization Server
- **Umgebung und Komponenten entwickeln sich weiter**
 - Möglicherweise immer wieder neue unbekannte Angriffe denkbar

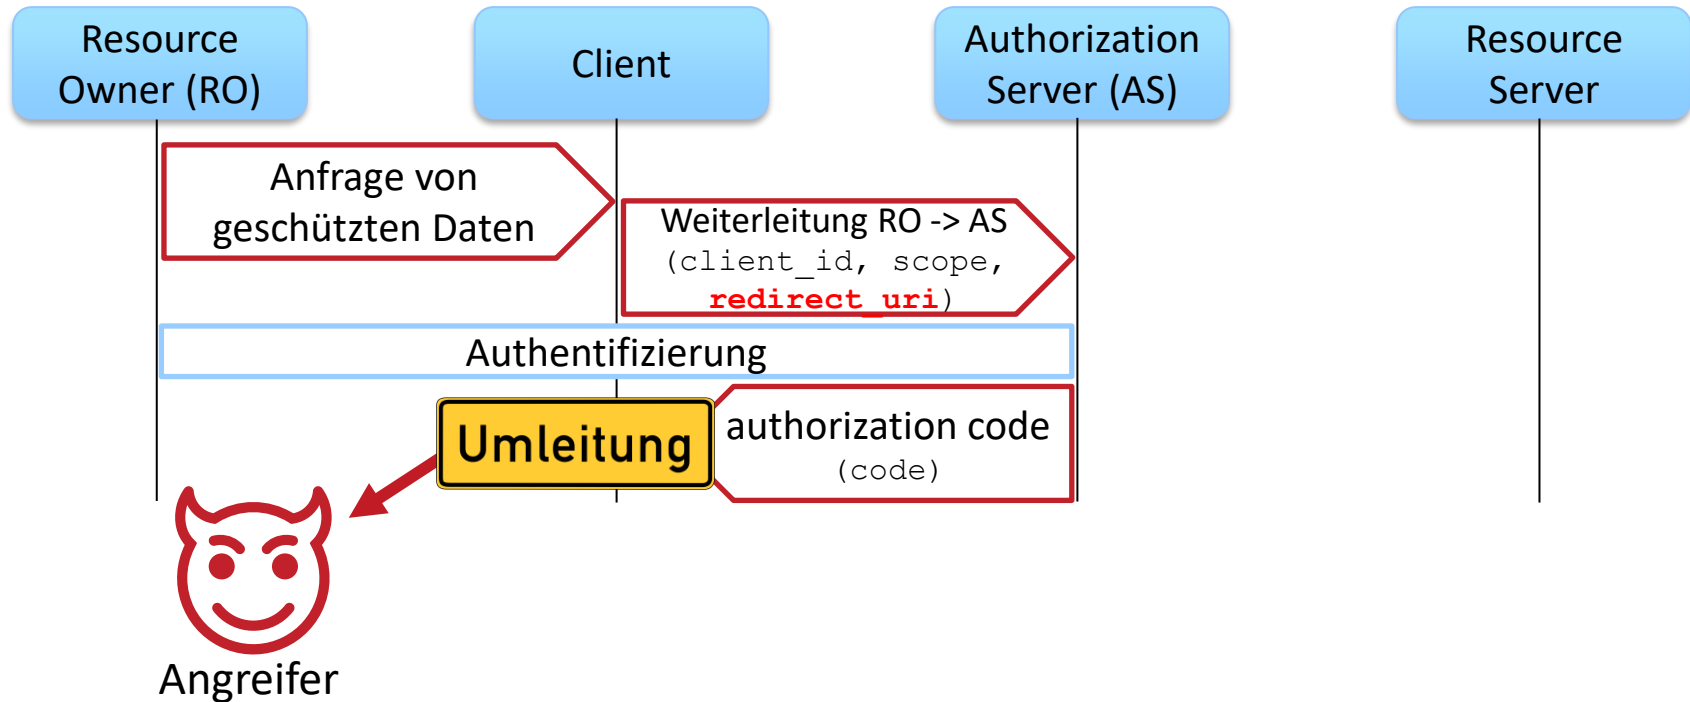
Anomalie-Erkennung für Angriffe auf OAuth 2.0

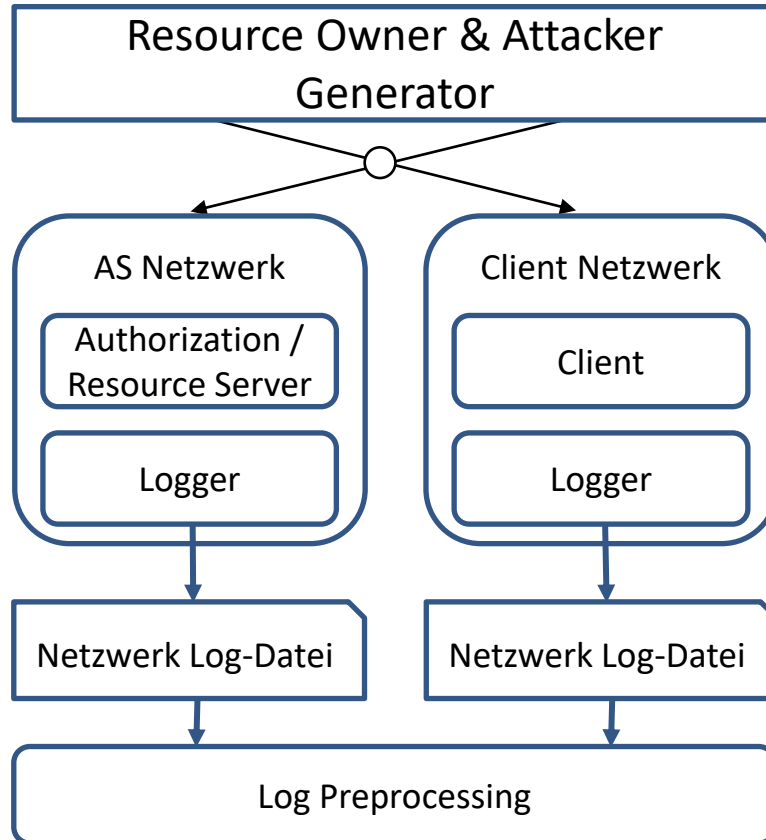
Anomalie-Erkennung für OAuth

- Bedrohungsart: Manipulation von Weiterleitungen

Anomalie-Erkennung für OAuth

- Bedrohungsart: Manipulation von Weiterleitungen





- 3627 Logeinträge im Testdatensatz insgesamt
- 44 Einträge, die Teil eines Angriffes sind
 - Angriffsrate 1,12 %
 - 2 Arten von Angriffen

Netzwerkdaten Beispiel ohne Angriff


| Method | URI | Is_attack |
|--------|--|-----------|
| GET | <code>/?next=http://localhost:5123/oauth/authorize ?response_type=code &client_id=A30qfzW7fbvhAN4Otlq4ZNFR &redirect_uri=http://localhost:8080/index.html</code> | 0 |
| GET | <code>/</code> | 0 |
| POST | <code>/</code> | 0 |
| POST | <code>/create_client</code> | 0 |

Netzwerkdaten Beispiel mit Angriff

| Method | URI | Is_attack |
|--------|--|-----------|
| GET | /oauth/authorize ?response_type=code &client_id=A30qfzW7fbvhAN 4Otlq4ZNFR &redirect_uri=http://evil-server.com | 1 |


- Clustering benötigt numerische Repräsentation der Daten
- Word2Vec
 - Methode aus der natürlichen Sprachverarbeitung
 - Wörter, die häufig zusammen auftauchen, stehen in einer Beziehung
 - Continuous Bag of Words (CBOW) vs. Skip-Gram
 - Wichtiger Hyperparameter: Fenstergröße
- Input Beispiele:
 - ['GET', 'api', 'v1.0', 'users']
 - ['GET', 'oauth', 'authorize', 'response_type', 'code', 'client_id', 'A30qfzW7fbvhAN4Otlq4ZNFR', 'redirect_uri', 'http:', 'evil-server.com']

Word2Vec Ergebnisse



Clustering


- Anomalien erkennen durch Clusterbildung
- Definition von Schwelle für Anomaliecluster
 - $\geq 5\%$ zählt als Anomalie
- Zwei Algorithmen wurden getestet
 - k-Means
 - Self-Organizing Maps




■ k-Means

- Vorbestimmte Anzahl von Clustern (k)
- Initial: Feste Anzahl (k) von zufälligen Cluster Mittelpunkten (*Centroids*) wird gewählt
- (a) Vektoren werden anhand der euklidischen Distanz dem nächsten Centroid zugeordnet – es bilden sich Cluster
- (b) Zu jedem entstandenen Cluster wird der tatsächliche Mittelpunkt berechnet
- Schritte a und b werden wiederholt, bis sich die Centroids nicht mehr ändern


Initial:



(a):

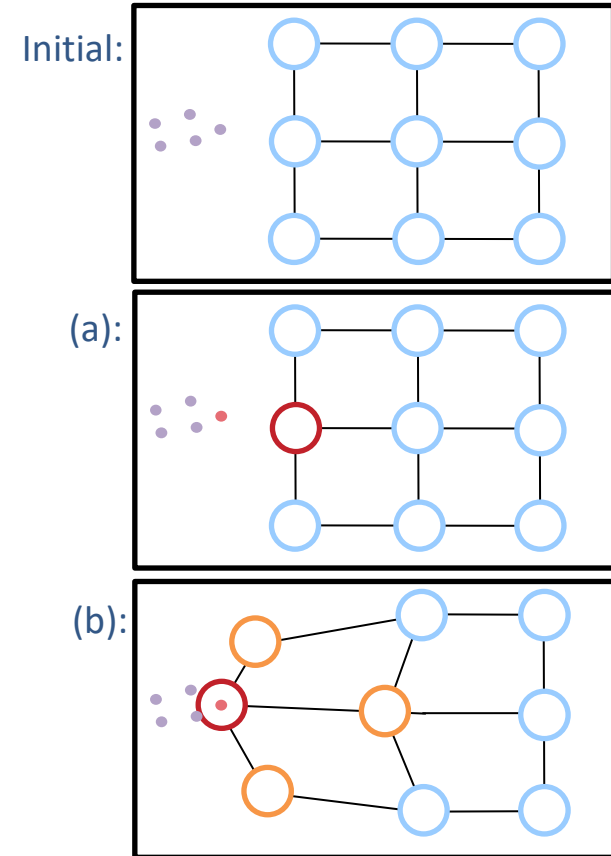


(b)(a):




■ Self-Organizing-Maps


- Clusteranzahl ergibt sich durch Algorithmus
- Initial: 2-dimensionales Raster von Neuronen wird initialisiert
- (a) Vektoren werden anhand der euklidischen Distanz, dem nächsten/ähnlichsten Neuron aus dem Raster zugeordnet -> Best Matching Unit (BMU)
- (b) Eine Nachbarschaftsfunktion wird angewendet um das Gewicht des BMU und benachbarten Neuronen anzupassen
- Schritte a und b werden für alle Vektoren mehrmals wiederholt für eine begrenzte Anzahl von Epochen



Clustering Ergebnis (k-Means) k=2



Clustering Ergebnis (k-Means) k=6




Clustering Ergebnis (k-Means) Clusteranzahl

- Verhalten bei Erhöhung der Clusteranzahl; Anomalieschwelle = 5%

| k | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 17 | 20 | 24 |
|------------------|------|------|------|------|------|------|------|------|------|------|
| Anomalie Cluster | 1 | 2 | 2 | 2 | 3 | 4 | 5 | 10 | 12 | 18 |
| Accuracy | 0,99 | 0,99 | 0,99 | 0,99 | 0,99 | 0,99 | 0,97 | 0,92 | 0,89 | 0,71 |
| Precision | 0,63 | 0,63 | 0,63 | 0,63 | 0,63 | 0,63 | 0,34 | 0,13 | 0,11 | 0,05 |

Clustering Ergebnis (SOM)



Ergebnisse beider Clustering Algorithmen

| | Word2Vec + K-Means | Word2Vec + SOM |
|-----------|--------------------|----------------|
| Accuracy | 0,993 | 0,993 |
| Yield | 1.0 | 1.0 |
| Precision | 0,637 | 0,637 |

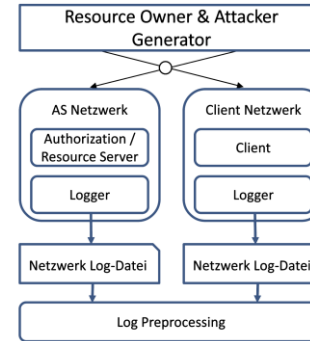
- Enkodierung durch Word2Vec hat die Ergebnisse maßgeblich beeinflusst
- Clustering Algorithmen entdecken offensichtliche Cluster
- Vorgehen trennt z.T. nur OAuth Netzwerkdaten von anderen Netzwerkdaten

Diskussion & zukünftige Ansatzpunkte


- Modellierung der Netzwerkdaten konzentriert sich auf Anwendungsdaten
 - Aggregation von realen Daten
- Word2Vec Performance
 - Untersuchung von anderen NLP-Methoden anhand von realen Daten
- Klassifizierung
 - Untersuchung von Supervised Learning Methoden auf realen Daten

Zusammenfassung

1. Leak von Credentials & Session Übernahme
2. Manipulation von Weiterleitungen
3. Umgehung von Integritätsmaßnahmen
4. Credential Injection



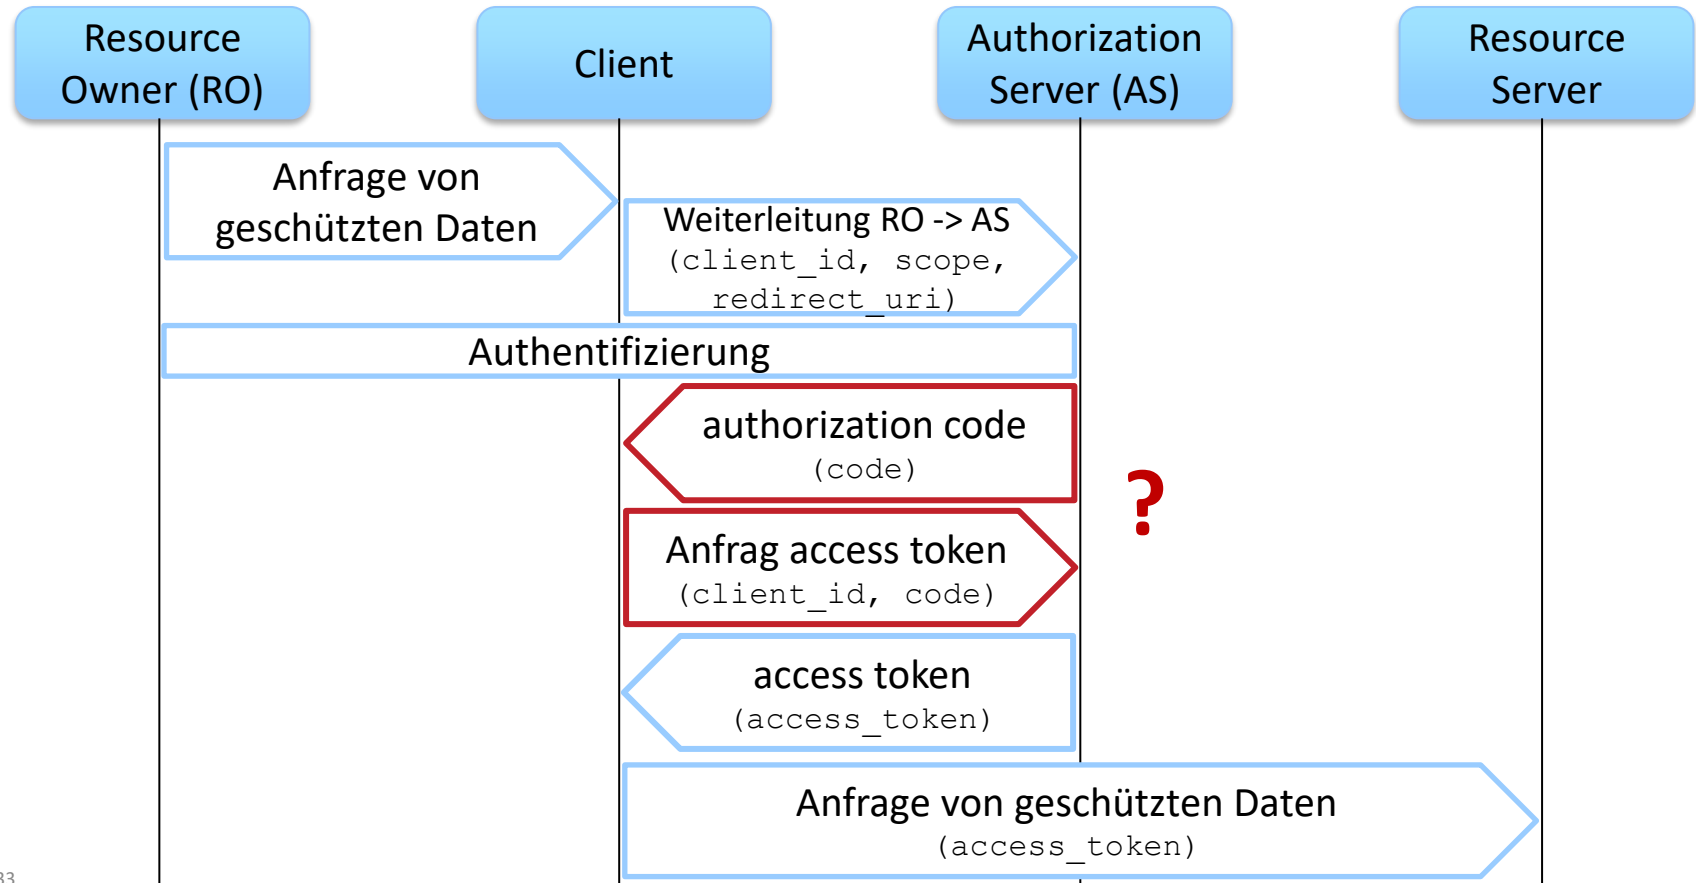
- 3627 Logeinträge im Testdatensatz insgesamt
- 44 Einträge, die Teil eines Angriffes sind
 - Angriffsrate 1,12 %
 - 2 Arten von Angriffen



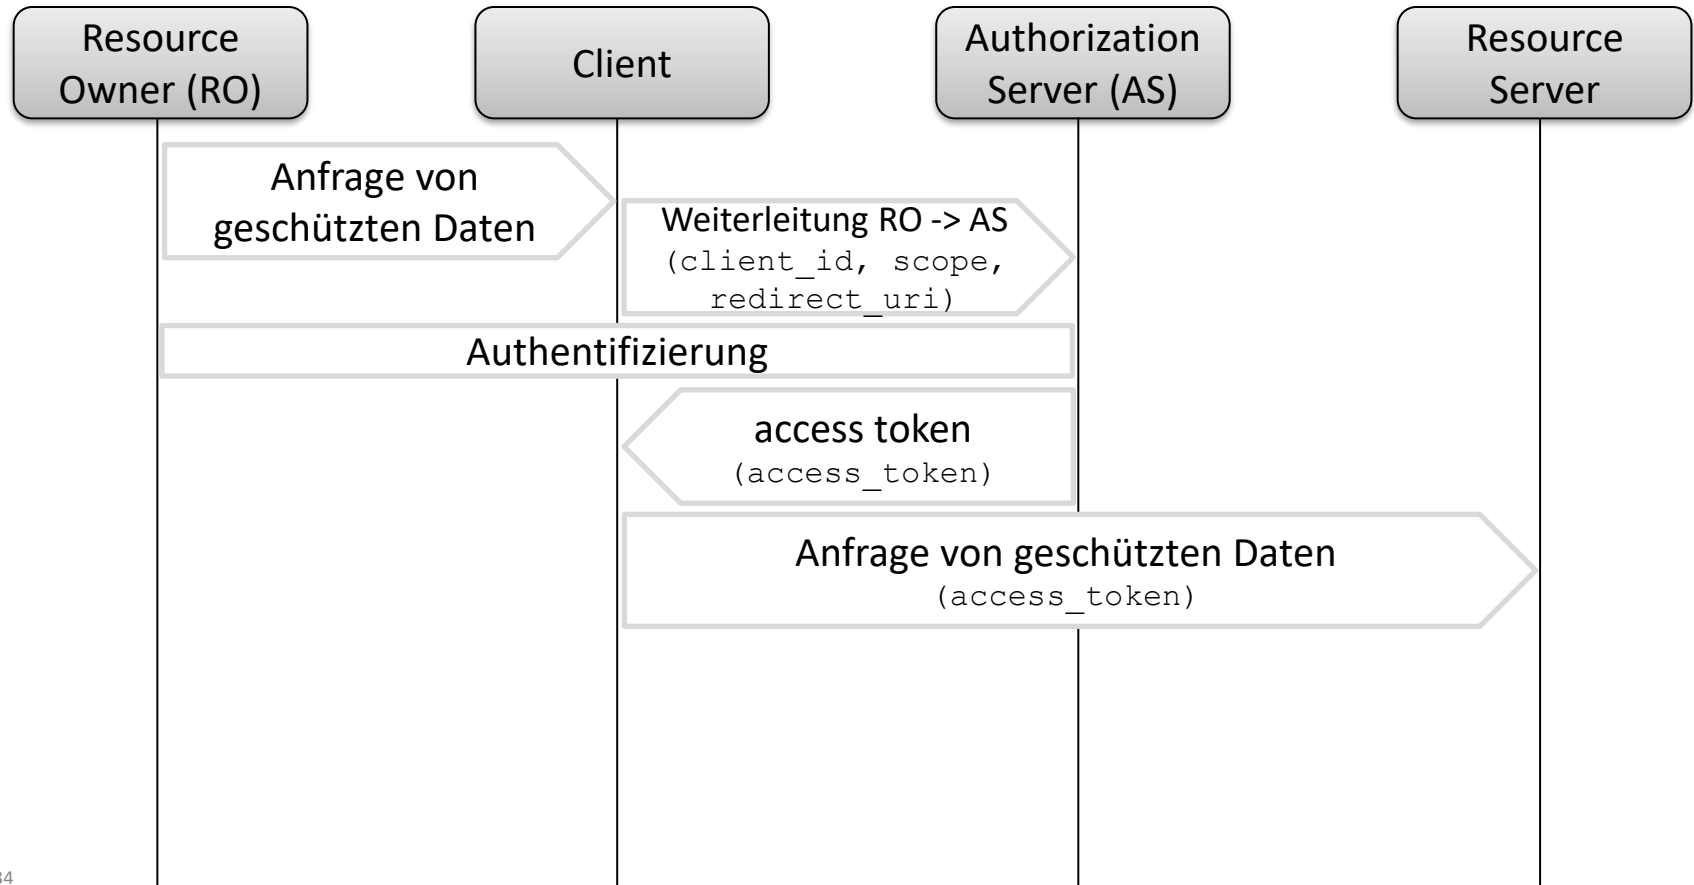
| | K-Means | SOM |
|-----------|---------|-------|
| Accuracy | 0,993 | 0,993 |
| Yield | 1.0 | 1.0 |
| Precision | 0,637 | 0,637 |

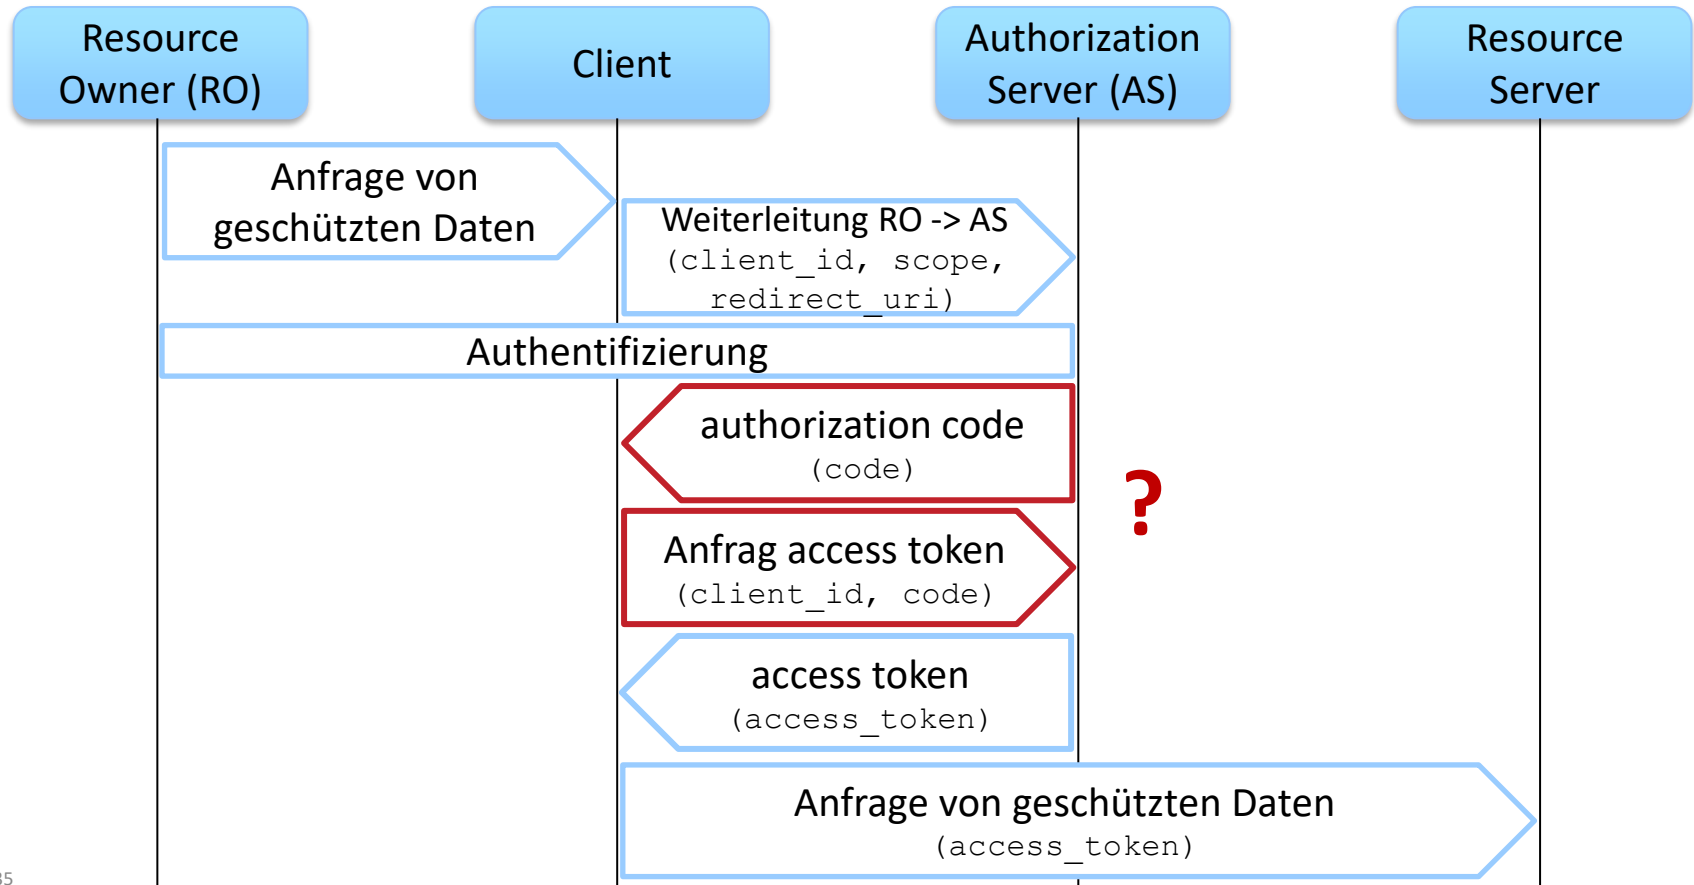
Quellen

- [Lod+20] - Torsten Lodderstedt et al. OAuth 2.0 security best current practice. In: IETF Web Authorization Protocol, Tech. Rep. draft-ietf-oauth-security-topics-16 (2020).
- [Har12] - Dick Hardt. Rfc 6749: The oauth 2.0 authorization framework. 2012.
- [Mik+13] - Tomas Mikolov et al. Efficient estimation of word representations in vector space. In: arXiv preprint arXiv:1301.3781 (2013).
- [Llo82] - S. Lloyd. Least squares quantization in PCM. In: IEEE Transactions on Information Theory 28.2 (1982), pp. 129–137. DOI: 10.1109/TIT.1982.1056489.
- [Koh90] - T. Kohonen. The self-organizing map. In: Proceedings of the IEEE 78.9 (1990), pp. 1464–1480. DOI: 10.1109/5.58325.



Implicit Grant





Anomalie Erkennung für OAuth

- Ansatzpunkt *redirect_uri* Parameter und HTTP Methode
 - Textuelle Repräsentation
 - Zwischen weiteren anderen Query-Parametern
 - Durch Implementierung in Clients sehr wenige Unterschiede in Netzwerkdaten
- Anomalie-Erkennung anhand der URI und der Methode von HTTP Requests
 - Testdatengenerierung
 - Enkodierung der textuellen Daten
 - Clustering

Anhang (1)

■ Self-Organizing Maps

– Euklidische Distanz:

- $$D(w, x) = \sqrt{\sum_{i=1}^N (w_i - x_i)^2} = \|r^2\|$$

- w = Gewichtsvektor, x = Inputvektor, N = Anzahl an Dimensionen von w und x

– Nachbarschaftsfunktion:

- $$h(r, t) = \exp\left(-\frac{\|r^2\|}{2\sigma^2(t)}\right)$$

- $\|r^2\|$ = Euklidische Distanz, t = Zeit/Iteration, σ^2 = Nachbarschaftsradius

- Xiaofei Qu et al. A survey on the development of self-organizing maps for unsupervised intrusion detection. In: Mobile networks and applications 26 (2021), pp. 808–829
- Corby Ziesman. Self-Organizing Maps. <https://slideplayer.com/slide/7798627/> (Abgerufen: 10.11.2023)

Anhang (2)

■ k-Means

- Centroid mit der minimalen Distanz

- $\arg \min_j \|x_i - \mu_j\|^2$
 - μ = Centroid, x = Inputvektor

- Mittelpunkt berechnen

- $c_j = \frac{1}{|\mu_j|} \sum_{x_i \in \mu_i} x_i$
 - c = Mittelpunkt = neuer μ

- Chris Piech. K Means. 2013. URL: <https://stanford.edu/~cpiech/cs221/handouts/kmeans.html> (Abgerufen: 15.10.2023).
- Jeremy Watt, Reza Borhani, Aggelos K. Katsaggelos. Machine Learning Refined: Notes, Exercises, Presentations, and Sample Chapters. URL: https://jermwatt.github.io/machine_learning_refined/notes/8_Linear_unsupervised_learning/8_5_Kmeans.html (Abgerufen: 15.10.2023)